ĐẠI HỌC PHENIKAA

TRƯỜNG CÔNG NGHỆ THÔNG TIN PHENIKAA



BÁO CÁO BÀI TẬP LỚN

NHÓM 3

MÔN: XỬ LÝ ẢNH

KHẢO SÁT ẢNH HƯỞNG CỦA XỬ LÝ ẢNH ĐẾN HIỆU NĂNG NHẬN DẠNG BIỂN BÁO GIAO THÔNG TRONG ĐIỀU KIỆN THIẾU SÁNG

Giảng viên hướng dẫn: Nguyễn Ngọc Giang

24100093 – Kiều Thị Thu Trang – 24100093@st.phenikaa-uni.edu.vn

24100012 – Trần Minh Sang – 24100012@st.phenikaa-uni.edu.vn

24102651 – Ngô Quang Thiện – 24102651@st.phenikaa-uni.edu.vn

Link Github dự án:

https://github.com/ZesyC/low-light-enhancement-for-traffic-sign-recognition

Hà Nội, tháng 10 năm 2026

MỤC LỤC

1 GIỚI THIỆU BÀI TOÁN 1
1.1 Đặt vấn đề 1
1.2 Yêu cầu và phạm vi nghiên cứu 1
1.3 Đầu vào và đầu ra của hệ thống 2
1.4 Các hướng tiếp cận và giải pháp khảo sát 2
1.5 Ý nghĩa và bố cục báo cáo 3
2 XÂY DỰNG TẬP DỮ LIỆU VÀ MÔ PHỎNG SUY GIẢM 3
2.1 Giới thiệu bộ dữ liệu GTSRB 3
2.2 Tiền xử lý và chuẩn hóa ảnh 4
2.3 Mô hình suy giảm thiếu sáng 4
2.4 Khảo sát histogram và cấu trúc ảnh 5
2.5 Bảo đảm điều kiện so sánh công bằng 6
3 CÁC PHƯƠNG PHÁP XỬ LÝ ẢNH 6
3.1 Nguyên tắc chung của khối tăng cường 6
3.2 Hiệu chỉnh Gamma 7
3.3 Cân bằng histogram toàn cục (HE) 8
3.4 Cân bằng histogram thích nghi có giới hạn tương phản (CLAHE) 9
3.5 Retinex đa tỉ lệ (Multi-Scale Retinex) 10
3.6 Các phương pháp tăng cường dựa trên học sâu 11
3.7 Minh họa trước và sau xử lý 12
3.8 Đánh giá chất lượng bằng PSNR và SSIM 13
4 THỬ NGHIỆM VÀ SO SÁNH KẾT QUẢ 14
4.1 Thiết lập mô hình kiểm chứng ResNet-18 14
4.2 Chỉ số đánh giá nhận dạng 15
4.3 Giao thức chọn tham số và tổng hợp số liệu 15
4.4 Nguồn kết quả và khả năng đối chiếu 16
4.5 Chất lượng ảnh trên tập con 430 ảnh 16
4.6 Accuracy và Macro-F1 trên cùng tập con 17
4.7 Đối chiếu trên toàn bộ 12.630 ảnh test 18
5 THẢO LUẬN KẾT QUẢ VÀ PHÂN TÍCH TƯƠNG QUAN 19
5.1 Chất lượng ảnh cao có bảo đảm nhận dạng tốt? 19
5.2 Phương pháp phân tích tương quan 19
5.3 Ablation: tách tác động của độ tối và nhiễu 20
5.4 Chi phí xử lý và khả năng triển khai 22
5.5 Giới hạn của thực nghiệm 23
6 ĐỀ XUẤT QUY TRÌNH TIỀN XỬ LÝ 23
6.1 Tiêu chí lựa chọn 23
6.2 Quy trình được lựa chọn 24
6.3 Phương án xử lý nhẹ bằng CLAHE 24
6.4 Tổ chức cài đặt và tái lập 25
6.5 Hướng cải thiện quy trình 25
7 KẾT LUẬN 25
TÀI LIỆU THAM KHẢO 27

1. GIỚI THIỆU BÀI TOÁN

1.1. Đặt vấn đề

Trong các hệ thống hỗ trợ lái xe và giao thông thông minh, biển báo cung cấp những thông tin trực tiếp về giới hạn tốc độ, hướng di chuyển và các tình huống cần cảnh báo. Khả năng nhận dạng đúng biển báo phụ thuộc trước hết vào chất lượng hình ảnh mà hệ thống tiếp nhận. Khi điều kiện chiếu sáng suy giảm, những đặc trưng quan trọng như đường viền, chữ số và mũi tên có thể trở nên khó phân biệt, ngay cả khi vị trí của biển báo đã được xác định.

Một hướng giải quyết thường được cân nhắc là tăng cường ảnh trước khi đưa vào mô hình nhận dạng. Tuy nhiên, tăng độ sáng không đồng nghĩa với phục hồi đầy đủ thông tin. Một phép biến đổi có thể làm vùng tối dễ quan sát hơn nhưng đồng thời khuếch đại nhiễu, thay đổi màu sắc hoặc làm nhòe những chi tiết nhỏ. Đối với biển báo giao thông, chỉ một nét bị mất trong chữ số hoặc một hướng mũi tên bị biến dạng cũng có thể dẫn đến dự đoán sai lớp.

Từ đó, bài toán được đặt ra là: *các phương pháp xử lý ảnh cải thiện chất lượng ảnh thiếu sáng đến mức nào, và sự cải thiện đó có thực sự giúp mô hình nhận dạng chính xác hơn hay không?* Đây là câu hỏi cần được trả lời bằng cả thước đo chất lượng ảnh lẫn kết quả nhận dạng trên cùng một điều kiện thực nghiệm.

Thứ nhất, suy giảm độ sáng đi kèm với suy giảm tỷ lệ tín hiệu trên nhiễu. Vùng tối có biên độ tín hiệu nhỏ, do đó nhiễu có thể chiếm tỷ lệ đáng kể so với thông tin hữu ích. Nếu chỉ áp dụng phép tăng sáng, phần nhiễu cũng được nâng lên cùng với cấu trúc của biển báo. Vì vậy, đánh giá một phương pháp trên ảnh chỉ làm tối bằng Gamma sẽ chưa phản ánh đầy đủ trường hợp ảnh đồng thời chứa nhiễu.

Thứ hai, chất lượng ảnh và chất lượng đặc trưng nhận dạng không hoàn toàn trùng nhau. PSNR phản ánh sai số cường độ điểm ảnh, còn SSIM xem xét độ tương đồng về cấu trúc cục bộ. Trong khi đó, mô hình nhận dạng học những đặc trưng phục vụ phân lớp. Một ảnh có sai số trung bình thấp vẫn có thể làm mất nét của chữ số; ngược lại, một ảnh khác ảnh tham chiếu về độ sáng vẫn có thể giữ được hình dạng cần thiết để nhận dạng.

Thứ ba, so sánh thuật toán cần kiểm soát các yếu tố ngoài xử lý ảnh. Nếu thay đổi kiến trúc mô hình hoặc huấn luyện lại riêng cho từng phương pháp tăng cường, rất khó tách biệt phần cải thiện đến từ ảnh và phần cải thiện đến từ mô hình. Bài tập lớn vì thế sử dụng duy nhất kiến trúc ResNet-18, huấn luyện trên ảnh gốc và giữ cố định trọng số khi so sánh các phép xử lý.

1.2. Yêu cầu và phạm vi nghiên cứu

Đề bài yêu cầu khảo sát ảnh hưởng của xử lý ảnh đến hiệu năng nhận dạng biển báo giao thông trong điều kiện thiếu sáng trên bộ dữ liệu GTSRB. Ảnh suy giảm được mô phỏng bằng Gamma kết hợp nhiễu Gaussian và Poisson ở nhiều mức độ. Các phương pháp tăng cường cần so sánh gồm hiệu chỉnh Gamma, cân bằng histogram (HE), cân bằng histogram cục bộ có giới hạn tương phản (CLAHE), Retinex, Zero-DCE, Retinexformer và phương pháp dựa trên diffusion.

Chất lượng ảnh được đánh giá bằng PSNR và SSIM. Hiệu năng nhận dạng được đo bằng

Accuracy và F1-score, trong đó Macro-F1 là tiêu chí chính để tránh đánh giá thiên lệch về các lớp có nhiều ảnh. Kết quả được dùng để phân tích tương quan giữa chất lượng ảnh và khả năng nhận dạng, từ đó lựa chọn quy trình tiền xử lý phù hợp.

Trong phạm vi triển khai, đầu vào là vùng ảnh đã chứa biển báo, không phải toàn cảnh giao thông. Hệ thống giải quyết bài toán phân loại vào một trong 43 lớp của GTSRB; chưa bao gồm phát hiện vị trí biển báo, theo dõi đối tượng hoặc xử lý video. Điều kiện thiếu sáng được tạo có kiểm soát từ ảnh gốc, do đó có ảnh tham chiếu tương ứng để tính PSNR và SSIM.

1.3. Đầu vào và đầu ra của hệ thống

Đầu vào: ảnh màu RGB sau khi cắt vùng quan tâm và đưa về kích thước 64×64 pixel. Giá trị cường độ được chuẩn hóa về đoạn $[0, 1]$. Từ ảnh gốc X, mô hình suy giảm tạo ảnh thiếu sáng Y với một mức tối và một hạt giống sinh nhiễu xác định.

Đầu ra của khối xử lý ảnh: ảnh tăng cường $\widehat{X} = E(Y)$ có cùng kích thước, thứ tự kênh màu và miền giá trị với đầu vào. Hàm E chỉ nhận ảnh thiếu sáng; ảnh tham chiếu và nhãn lớp không được đưa vào thuật toán tăng cường.

Đầu ra của khối nhận dạng: vector 43 giá trị dự đoán và nhãn lớp có giá trị lớn nhất. Trước khi đi qua ResNet-18, ảnh được nội suy lên 224×224 và chuẩn hóa theo ImageNet. Việc đổi kích thước này chỉ phục vụ mô hình nhận dạng; các phép tăng cường và đo chất lượng ảnh vẫn thực hiện ở 64×64.

Đầu ra nghiên cứu: bảng so sánh PSNR, SSIM, Accuracy, Macro-F1, thời gian xử lý; hình ảnh trực quan; phân tích ablation và tương quan; cùng một phương án tiền xử lý được chọn trên validation trước khi đánh giá test.

1.4. Các hướng tiếp cận và giải pháp khảo sát

Nhóm phương pháp truyền thống tác động trực tiếp lên cường độ hoặc phân bố mức xám. Gamma điều chỉnh phi tuyến từng điểm ảnh; HE phân phối lại histogram toàn cục; CLAHE xử lý theo vùng; Retinex ước lượng quan hệ giữa thành phần chiếu sáng và phản xạ. Những phương pháp này có ưu điểm dễ giải thích, ít tham số và chi phí tính toán tương đối thấp.

Nhóm phương pháp học sâu sử dụng thông tin đã học để điều chỉnh hoặc phục hồi ảnh. Zero-DCE ước lượng đường cong tăng sáng, Retinexformer kết hợp biểu diễn chiếu sáng với Transformer, còn phương pháp diffusion được khảo sát thực hiện phục hồi có điều kiện trong miền wavelet. Dự án sử dụng trọng số công bố của tác giả, không huấn luyện lại các bộ tăng cường trên GTSRB [3, 4, 5].

Giải pháp của bài tập lớn không giả định một nhóm phương pháp luôn tốt hơn nhóm còn lại. Tất cả được đánh giá trên cùng ảnh suy giảm, cùng tập mẫu và cùng các checkpoint ResNet-18. Mốc đối chứng là *Identity*, tức ảnh tối giữ nguyên. Ảnh gốc *Clean* được dùng làm tham chiếu và kiểm tra hiệu năng nhận dạng khi chưa áp dụng mô hình suy giảm.

1.5. Ý nghĩa và bố cục báo cáo

Về kiến thức xử lý ảnh, đề tài kết nối phép biến đổi điểm, histogram, lọc Gaussian, mô hình nhiễu và các chỉ số chất lượng trong một quy trình thống nhất. Về thực nghiệm, đề tài làm rõ sự đánh đổi giữa độ sáng, mức nhiễu, tính toàn vẹn của chi tiết và chi phí suy luận. ResNet-18 đóng vai trò công cụ kiểm chứng thông tin được giữ lại sau xử lý, thay vì là đối tượng tối ưu chính của báo cáo.

Các phần tiếp theo lần lượt trình bày dữ liệu và mô hình suy giảm; cơ sở và cài đặt các phương pháp tăng cường; thiết lập cùng kết quả thực nghiệm; phân tích tương quan và ảnh hưởng của nhiễu; quy trình tiền xử lý được đề xuất; cuối cùng là kết luận và giới hạn của nghiên cứu.

2. XÂY DỰNG TẬP DỮ LIỆU VÀ MÔ PHỎNG SUY GIẢM

2.1. Giới thiệu bộ dữ liệu GTSRB

German Traffic Sign Recognition Benchmark (GTSRB) là bộ dữ liệu phân loại biển báo giao thông với 43 lớp [1]. Trong dữ liệu dự án, tập huấn luyện chính thức có 39.209 ảnh và tập kiểm thử chính thức có 12.630 ảnh. Các ảnh khác nhau về góc quan sát, kích thước biển báo, nền cảnh và điều kiện chiếu sáng. Đây là những yếu tố khiến việc tăng cường ảnh cần giữ được đặc trưng hình học và màu sắc thay vì chỉ nâng giá trị sáng trung bình.

Một số ảnh huấn luyện được chụp liên tiếp từ cùng một biển báo. Những ảnh thuộc cùng chuỗi quan sát có mức tương đồng cao. Nếu chia train và validation ngẫu nhiên ở cấp ảnh, các khung gần giống nhau có thể xuất hiện ở cả hai tập, làm kết quả validation lạc quan hơn khả năng tổng quát thực tế. Vì vậy, dự án chia dữ liệu theo lớp và *track*, giữ các ảnh cùng track trong một tập.

Bảng 1. Phân chia dữ liệu trong quy trình ResNet-18.

Tập dữ liệu	Số ảnh	Vai trò
Huấn luyện	31.350	Huấn luyện ResNet-18 trên ảnh gốc
Validation	7.829	Chọn checkpoint và đánh giá trong huấn luyện
Cách ly	30	Loại track có ảnh trùng pixel với test khỏi huấn luyện
Official test	12.630	Kiểm thử toàn bộ tập chính thức
Validation chọn xử lý	1.290	30 ảnh/lớp để chọn tham số tăng cường
Test khảo sát	430	10 ảnh/lớp cho notebook và ablation

Tập cách ly gồm 30 ảnh thuộc track có ảnh trùng pixel với tập test, theo kiểm kê được ghi trong dự án. Toàn bộ track được tách ra để tránh chỉ loại những ảnh trùng chính xác nhưng vẫn giữ các khung gần kề. Tổng số ảnh train, validation và cách ly bằng 39.209; test chính thức được giữ riêng. Hạt giống chia dữ liệu là 42.

Các tập 1.290 và 430 ảnh là những tập con của validation và test, không phải dữ liệu bổ sung. Việc lấy cùng số ảnh mỗi lớp giúp khảo sát cân bằng 43 lớp và giảm chi phí chạy nhiều phương pháp. Tuy nhiên, kết quả trên 430 ảnh không đại diện đầy đủ cho phân bố tần suất của 12.630 ảnh test; báo cáo vì thế trình bày hai phạm vi này thành các bảng riêng.

2.2. Tiền xử lý và chuẩn hóa ảnh

2.2.1. Cắt vùng quan tâm

Vùng quan tâm (Region of Interest, ROI) được xác định bằng tọa độ chú thích của dữ liệu. Dự án mở rộng vùng này thêm 5% kích thước theo mỗi phía, đồng thời giới hạn khung cắt trong kích thước ảnh. Phần lề nhỏ giúp giữ đường viền biển báo và một lượng ngữ cảnh xung quanh; nếu cắt sát quá mức, những pixel biên có thể bị loại bỏ trước khi thuật toán tăng cường hoạt động.

Với ROI (x_1, y_1, x_2, y_2) có điểm cuối bao gồm trong vùng, mã nguồn chuyển x_2, y_2 sang mốc cuối không bao gồm bằng cách cộng 1. Sau đó tính độ mở rộng theo chiều rộng và chiều cao, làm tròn ra ngoài bằng phép lấy sàn/lấy trần và chặn tại biên ảnh. Quy ước này tránh bỏ mất hàng hoặc cột pixel cuối cùng khi cắt bằng thư viện ảnh.

2.2.2. Đổi kích thước và miền cường độ

Ảnh ROI được đổi sang RGB, nội suy song tuyến tính về 64×64 rồi lưu dưới dạng chuẩn hóa:

$$X \in [0,1]^{64\times64\times3}, \qquad X = \frac{I_{\text{8-bit}}}{255}. \tag{1}$$

Nội suy song tuyến tính sử dụng tổ hợp có trọng số của các pixel lân cận. Cách làm này phù hợp với yêu cầu đưa các vùng biển báo có kích thước khác nhau về cùng đầu vào, nhưng có thể làm mềm các nét vốn rất nhỏ. Do đó, quá trình phóng lên 224×224 sau tăng cường không tạo lại thông tin đã mất ở bước chuẩn hóa 64×64.

Các thuật toán làm việc với số thực `float32`. Riêng HE và CLAHE chuyển ảnh sang số nguyên 8 bit để dùng các phép xử lý histogram của OpenCV rồi chuyển trở lại số thực. Việc lượng tử hóa ở hai phương pháp này là một phần của cách cài đặt, cần được phân biệt với các phương pháp thực hiện trực tiếp trên giá trị liên tục.

2.3. Mô hình suy giảm thiếu sáng

Mô hình suy giảm được áp dụng theo thứ tự cố định: Gamma làm tối, nhiễu Poisson, nhiễu Gaussian và cuối cùng chặn về $[0, 1]$. Với một pixel của ảnh gốc X, quá trình được mô tả bởi:

$$U = X^{\gamma_d}, \tag{2}$$

$$V = \frac{\mathcal{P}(pU)}{p}, \tag{3}$$

$$Y = \text{clip}\big(V + \varepsilon, 0, 1\big), \quad \varepsilon \sim \mathcal{N}(0, \sigma_n^2). \tag{4}$$

Trong đó $\gamma_d > 1$ điều khiển mức tối, p là hệ số Poisson và σ_n là độ lệch chuẩn nhiễu Gaussian. Phép lũy thừa áp dụng theo từng kênh RGB trong miền ảnh chuẩn hóa; đây là mô hình suy giảm tổng hợp, không phải mô phỏng đầy đủ quá trình thu nhận ánh sáng của cảm biến RAW.

2.3.1. Vai trò của Gamma làm tối

Với $0 < X < 1$ và $\gamma_d > 1$, ta có $X^{\gamma_d} < X$. Khi tăng γ_d, vùng trung gian bị kéo về cường độ thấp mạnh hơn. Ví dụ, một pixel có cường độ 0,5 trở thành khoảng 0,354; 0,218 và 0,125 khi γ_d lần lượt bằng 1,5; 2,2 và 3,0. Điểm đen 0 và điểm trắng 1 vẫn được giữ ở hai đầu miền.

Điều này giải thích vì sao ảnh tối có histogram dịch về bên trái mà vùng phản xạ rất sáng vẫn có thể còn rõ. Phép Gamma tạo được nhiều mức suy giảm với tham số dễ kiểm soát, đồng thời vẫn giữ quan hệ xác định giữa ảnh gốc và ảnh tối khi chưa thêm nhiễu.

2.3.2. Vai trò của nhiễu Poisson và Gaussian

Trước bước chặn, nhiễu Poisson trong công thức (3) có kỳ vọng U và phương sai U/p. Khi p giảm, mức dao động tăng. Mặc dù phương sai tuyệt đối nhỏ ở vùng tối, độ lệch chuẩn tương đối so với tín hiệu là $1/\sqrt{pU}$, có thể lớn khi U rất nhỏ. Đây là đặc điểm quan trọng khi khảo sát tính nhạy nhiễu của phép tăng sáng.

Nhiễu Gaussian được cộng với độ lệch chuẩn cố định cho mọi pixel. Trong mô hình này, nó đại diện cho một thành phần nhiễu cộng đơn giản. Khi tín hiệu sau Gamma nhỏ, cùng một mức nhiễu Gaussian sẽ gây ảnh hưởng tương đối lớn hơn đến nội dung. Bước chặn cuối cùng bảo đảm ảnh nằm trong miền hợp lệ, nhưng cũng làm phân bố nhiễu gần 0 hoặc 1 không còn hoàn toàn đối xứng.

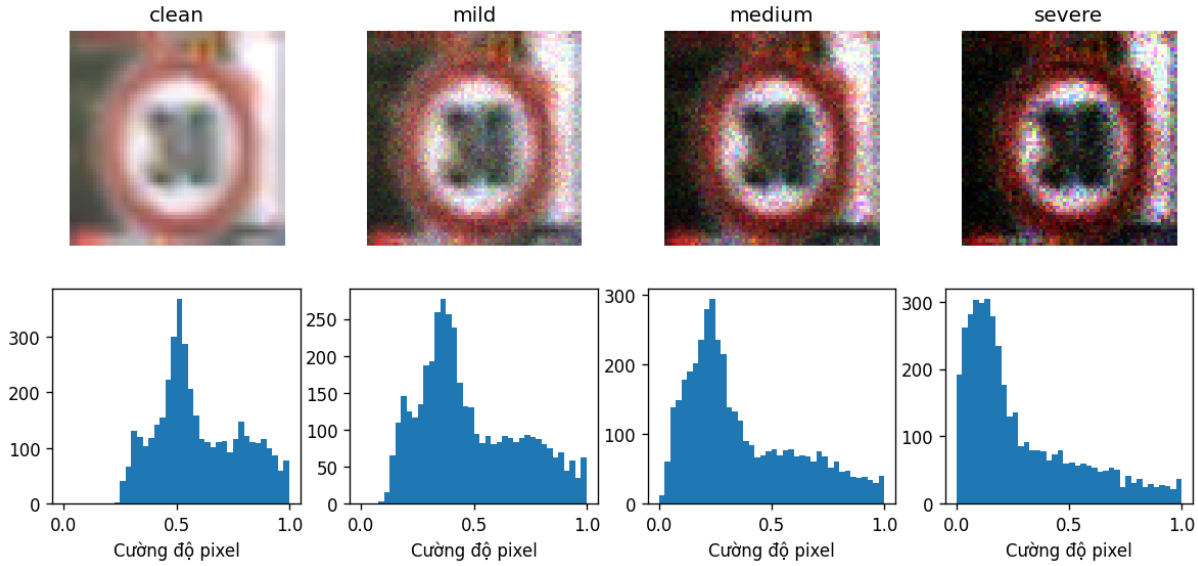
Bảng 2. Ba mức suy giảm sử dụng trong thí nghiệm.

Mức độ	γ_d	Poisson p	Gaussian σ_n
Nhẹ (mild)	1,5	120	0,005
Vừa (medium)	2,2	60	0,010
Nặng (severe)	3,0	30	0,020

Ba mức trong Bảng 2 thay đổi đồng thời độ tối và hai thành phần nhiễu. Vì vậy, sự chênh lệch giữa mức nhẹ và mức nặng phản ánh tổng tác động của cả ba yếu tố. Muốn xác định riêng ảnh hưởng của nhiễu, cần dùng thí nghiệm ablation giữ nguyên Gamma và lần lượt bật/tắt từng loại nhiễu, được trình bày ở phần thảo luận.

2.4. Khảo sát histogram và cấu trúc ảnh

Quan sát Hình 1, vùng nền sáng của biển báo suy giảm rõ khi tăng mức tối. Các nét số trở nên khó phân biệt với nền và nhiễu màu xuất hiện trên cả vùng tương đối đồng nhất. Histogram tập trung ngày càng nhiều tại cường độ thấp; độ tương phản giữa các cấu trúc hữu ích không thể được suy ra chỉ từ việc histogram còn trải rộng đến gần 1.



Hình 1. Ảnh tham chiếu và ba mức suy giảm trên cùng một crop validation. Hàng dưới là histogram cường độ xám; trục đứng biểu thị số pixel. Hình trích trực tiếp từ notebook ResNet-18, noise seed 101.

Trên riêng ảnh minh họa này, PSNR của mức nhẹ, vừa và nặng lần lượt là 17,2577; 12,0942; 9,5306 dB. SSIM tương ứng là 0,7120; 0,5494; 0,3855. Đây là số đo của một ảnh validation được chọn theo quy tắc trong notebook, không phải giá trị trung bình của toàn bộ tập test.

Histogram chỉ biểu diễn tần suất cường độ, không chứa vị trí của pixel. Hai ảnh có histogram gần nhau vẫn có thể khác hoàn toàn về bố trí đường viền hoặc chữ số. Vì vậy, phân tích histogram trong báo cáo luôn đi kèm quan sát ảnh, SSIM và kết quả nhận dạng, tránh kết luận chất lượng chỉ từ sự dịch chuyển phân bố mức xám.

2.5. Bảo đảm điều kiện so sánh công bằng

Hạt giống sinh nhiễu được xác định từ noise seed, mã mẫu và tên điều kiện. Ba noise seed là 101, 202 và 303. Với cùng mã ảnh, cùng mức suy giảm và cùng noise seed, tất cả các phương pháp nhận đúng một ảnh tối. Cách thiết kế này tránh việc một thuật toán vô tình được đánh giá trên nhiễu nhẹ hơn thuật toán khác.

Ảnh gốc chỉ được sử dụng để tính chất lượng sau tăng cường. Nhãn lớp chỉ phục vụ huấn luyện bộ nhận dạng, chọn tham số bằng validation và tính metric. Các tập con, cấu hình và checkpoint được khóa trước test. Những ràng buộc này giúp quy kết thay đổi kết quả chủ yếu cho phép xử lý ảnh đang khảo sát trong phạm vi giao thức đã định.

3. CÁC PHƯƠNG PHÁP XỬ LÝ ẢNH

3.1. Nguyên tắc chung của khối tăng cường

Nhiệm vụ của khối tăng cường là biến đổi ảnh thiếu sáng Y thành ảnh $\widehat{X}$ có độ sáng và cấu trúc phù hợp hơn cho quan sát cũng như nhận dạng. Mọi phương pháp đều tuân thủ cùng giao diện: nhận một ảnh RGB 64×64 trong $[0, 1]$, trả lại ảnh cùng kích thước và không

truy cập ảnh tham chiếu. Điều này cho phép đánh giá phương pháp truyền thống và học sâu trong cùng quy trình.

Identity giữ nguyên ảnh tối: $E(Y) = Y$. Đây là mốc bắt buộc để xác định lợi ích thực của tăng cường. Một thuật toán có ảnh đầu ra sáng hơn nhưng Accuracy hoặc Macro-F1 thấp hơn Identity được xem là làm giảm hiệu quả nhận dạng trong điều kiện đó.

Clean là ảnh gốc trước suy giảm. Clean không phải một thuật toán phục hồi và không tham gia lựa chọn bộ tăng cường. Vai trò của nó là tạo mức hiệu năng tham chiếu, cho biết khoảng cách còn lại giữa ảnh sau xử lý với điều kiện đầu vào ban đầu.

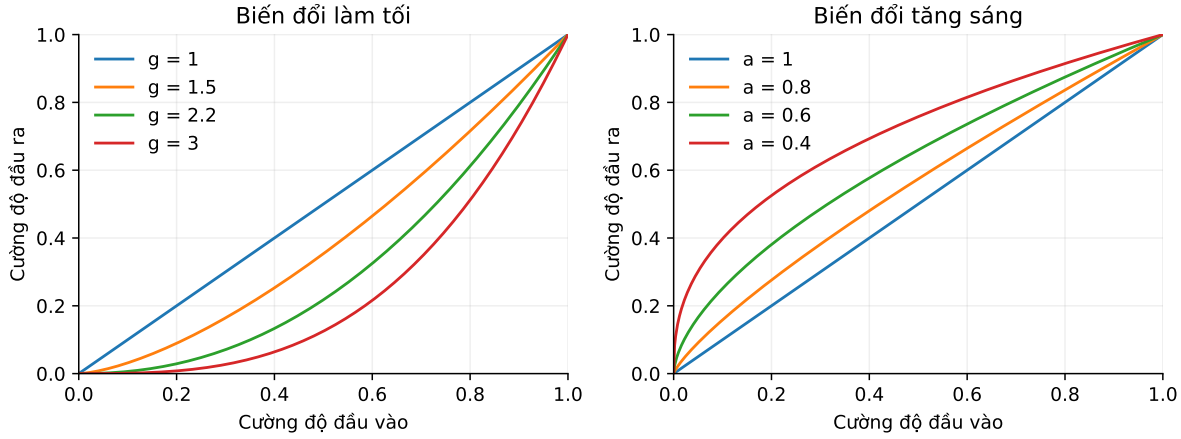
3.2. Hiệu chỉnh Gamma

3.2.1. Cơ sở toán học

Hiệu chỉnh Gamma tăng sáng bằng phép lũy thừa:

$$\widehat{X} = Y^{\alpha}, \qquad 0 < \alpha < 1. \tag{5}$$

Với cường độ nằm giữa 0 và 1, số mũ nhỏ hơn 1 làm đầu ra lớn hơn đầu vào. Khi α giảm, mức nâng sáng mạnh hơn. Ví dụ, pixel 0,1 trở thành 0,158 với $\alpha = 0,8$; 0,251 với $\alpha = 0,6$ và 0,398 với $\alpha = 0,4$.



Hình 2. Đường cong Gamma làm tối và tăng sáng trên miền $[0, 1]$. Đây là đồ thị giải tích của phép biến đổi, không phải kết quả đo trên tập ảnh.

Trong trường hợp lý tưởng chỉ có Gamma làm tối, lựa chọn $\alpha = 1/\gamma_d$ sẽ khôi phục cường độ ban đầu vì $(X^{\gamma_d})^{1/\gamma_d} = X$. Khi có Poisson, Gaussian và bước chặn, phép biến đổi này không còn là nghịch đảo chính xác. Đặc biệt, clipping đã loại bỏ một phần thông tin nên không thể đảo ngược chỉ bằng một hàm điểm.

3.2.2. Ảnh hưởng đến nhiễu và cách cài đặt

Độ nhạy cục bộ của hàm tăng sáng đối với đầu vào được mô tả bởi:

$$\frac{\mathrm{d}Y^{\alpha}}{\mathrm{d}Y} = \alpha Y^{\alpha-1}. \tag{6}$$

Khi Y nhỏ và $\alpha < 1$, hệ số này có thể lớn. Với nhiễu nhỏ, cách xấp xỉ tuyến tính cho thấy nhiễu đầu vào có thể bị khuếch đại trong vùng tối. Đây là cơ sở để giải thích tại sao giảm Gamma quá mạnh làm hình ảnh sáng rõ nhưng cũng khiến nhiễu hạt nổi bật hơn.

Trong mã nguồn, Gamma được thực hiện trực tiếp bằng phép toán lũy thừa trên mảng RGB số thực, không chuyển qua ảnh 8 bit. Không có phép lọc không gian hoặc khử nhiễu kèm theo. Lưới validation khảo sát $\alpha \in \{0,4; 0,6; 0,8\}$. Notebook ResNet-18 chọn $\alpha = 0,8$, tương ứng mức tăng sáng tương đối nhẹ.

Ưu điểm: cài đặt đơn giản, chi phí thấp, giữ quan hệ đơn điệu của cường độ. **Hạn chế:** sử dụng cùng quy tắc ở mọi vị trí, không thích ứng với ánh sáng không đồng đều và không phân biệt nét thật với nhiễu. Do áp dụng phi tuyến theo từng kênh, phương pháp cũng không bảo đảm giữ nguyên tỷ lệ giữa các thành phần màu.

3.3. Cân bằng histogram toàn cục (HE)

3.3.1. Nguyên lý phân phối lại mức xám

Histogram mô tả số pixel xuất hiện tại mỗi mức cường độ. Với ảnh có L mức xám, ký hiệu n_k là số pixel tại mức k và N là tổng số pixel. Histogram chuẩn hóa và hàm phân phối tích lũy được viết:

$$p(k) = \frac{n_k}{N}, \qquad C(k) = \sum_{j=0}^{k} p(j). \tag{7}$$

Một phép ánh xạ cân bằng điển hình đưa mức xám về:

$$T(k) = \text{round}\left((L-1)\frac{C(k) - C_{\text{min}}}{1 - C_{\text{min}}} \right), \tag{8}$$

trong đó C_{min} là giá trị CDF khác 0 đầu tiên. Trường hợp ảnh hằng cần được xử lý riêng để tránh mẫu số bằng 0. HE giúp mở rộng khoảng mức xám đang bị tập trung, song không bảo đảm histogram rời rạc sau biến đổi sẽ phẳng hoàn toàn.

3.3.2. Xử lý trên kênh độ sáng

Nếu cân bằng độc lập R, G và B, ba phép ánh xạ có thể khác nhau và làm biến đổi mạnh màu sắc. Dự án chuyển ảnh từ RGB sang YCrCb, chỉ áp dụng `equalizeHist` trên kênh Y, giữ hai kênh màu rồi chuyển lại RGB. Trước khi đổi không gian màu, ảnh được nhân 255, làm tròn và chuyển sang `uint8`; sau xử lý được chia 255 để trở lại $[0, 1]$.

Việc chỉ tác động lên Y giúp hạn chế sai lệch màu so với cân bằng độc lập từng kênh. Tuy nhiên, quá trình lượng tử hóa và chặn miền khi chuyển đổi vẫn có thể làm thay đổi đầu ra. Do đó, không nên mô tả HE như một phép biến đổi bảo toàn màu tuyệt đối.

HE sử dụng thống kê toàn ảnh, nên vùng nền sáng và vùng biển báo tối cùng đóng góp vào một hàm ánh xạ. Trong ảnh có chiếu sáng không đồng đều, cùng một mức xám thuộc các vùng khác nhau vẫn được xử lý giống nhau. Đây là lý do tăng tương phản toàn cục có thể làm một số vùng dễ quan sát hơn nhưng đồng thời bão hòa các vùng vốn đã sáng [2].

Ưu điểm: không phải chọn tham số tăng sáng, dễ triển khai và nhanh. **Hạn chế:** có thể tăng nhiễu, thay đổi phân bố sáng quá mạnh và làm mất thông tin trong vùng bị bão hòa. Với crop nhỏ, histogram cũng nhạy với tỷ lệ nền và kích thước phần biển báo trong ảnh.

3.4. Cân bằng histogram thích nghi có giới hạn tương phản (CLAHE)

3.4.1. Từ xử lý toàn cục đến xử lý cục bộ

CLAHE chia ảnh thành một lưới ô và xây dựng phép ánh xạ histogram cho từng ô. Cách tiếp cận cục bộ giúp xử lý các vùng có điều kiện chiếu sáng khác nhau. Tuy nhiên, nếu cân bằng cục bộ không giới hạn, một vùng gần như đồng nhất có thể bị kéo giãn tương phản mạnh và làm nhiễu nổi rõ. CLAHE giải quyết điều này bằng cách giới hạn chiều cao histogram trước khi xây dựng CDF.

Quy trình gồm bốn bước: tính histogram mỗi ô; cắt các bin vượt ngưỡng; phân phối lại lượng dư; xây dựng ánh xạ và nội suy giữa các ô. Nội suy ở ranh giới giúp giảm hiện tượng xuất hiện các khối vuông sau xử lý. Trong triển khai của dự án, toàn bộ phép này được áp dụng trên kênh Y, tương tự HE.

3.4.2. Ý nghĩa tham số và ảnh hưởng kích thước ảnh

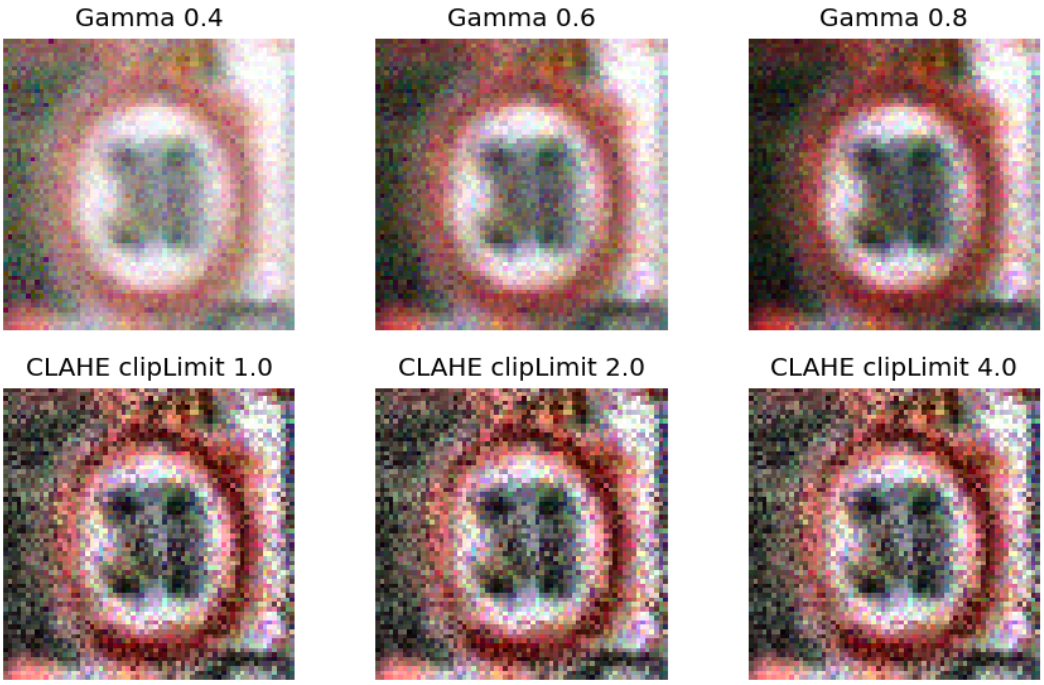
Hai tham số chính là `clipLimit` và `tileGridSize`. Tham số thứ nhất điều khiển mức giới hạn histogram theo quy ước OpenCV; không phải ngưỡng cường độ sáng của pixel. Tham số thứ hai là số ô theo hai chiều, không phải kích thước mỗi ô tính bằng pixel. Với ảnh 64×64, lưới 8×8 tạo ô khoảng 8×8 pixel, còn lưới 4×4 tạo ô khoảng 16×16 pixel.

Ở ô quá nhỏ, số mẫu dùng để ước lượng histogram ít, dễ khiến thống kê bị ảnh hưởng bởi nhiễu và từng nét của biển báo. Lưới thưa hơn có thể ổn định hơn nhưng mức thích ứng không gian cũng giảm. Do vậy, cấu hình tốt trên ảnh độ phân giải cao chưa chắc tốt khi chuyển sang crop 64×64.

Lưới validation khảo sát ba giá trị clip limit $\{1, 2, 4\}$ kết hợp hai lưới $\{4\times4, 8\times8\}$. Notebook chọn clip limit bằng 2 và lưới 4×4. Đây là kết quả lựa chọn bằng khả năng nhận dạng trên validation, không phải tham số được chọn bằng cách nhìn ảnh test.

Một điểm đáng chú ý là ba clip limit 1, 2 và 4 với lưới 8×8 cho cùng điểm validation trong notebook. Với ô 8×8 có 64 pixel và 256 bin, việc quy đổi ngưỡng cắt về số nguyên trong OpenCV có thể đưa các giá trị này về cùng ngưỡng hiệu dụng. Vì vậy, đổi tham số danh nghĩa chưa chắc tạo ra đầu ra khác trên ảnh nhỏ. Nhận định này phù hợp với cài đặt thư viện và quan sát thí nghiệm, không nên suy rộng thành tính chất chung cho mọi kích thước ảnh.

Ưu điểm: tăng tương phản theo vùng, kiểm soát tốt hơn sự khuếch đại histogram và có chi phí tính toán thấp hơn nhiều so với các bộ phục hồi sâu. **Hạn chế:** vẫn có thể làm nhiễu rõ hơn; chất lượng phụ thuộc tương tác giữa clip limit, lưới và độ phân giải.



Hình 3. Ảnh hưởng của Gamma và clip limit trên cùng ảnh tối mức vừa. Hàng dưới giữ lưới CLAHE 8×8 để minh họa riêng tham số clip limit; đây không phải cấu hình CLAHE được chọn cuối cùng.

3.5. Retinex đa tỉ lệ (Multi-Scale Retinex)

3.5.1. Mô hình phản xạ và chiếu sáng

Retinex xem ảnh quan sát là tích của thành phần phản xạ R và chiếu sáng L:

$$I(x, y) = R(x, y)L(x, y). \tag{9}$$

Nếu có thể ước lượng thành phần chiếu sáng biến đổi chậm, ta có thể giảm ảnh hưởng của nó và làm rõ cấu trúc phản xạ. Trong miền log, tích trở thành tổng; một dạng Single-Scale Retinex sử dụng ảnh làm mờ Gaussian để xấp xỉ thành phần chiếu sáng:

$$r_s = \log(Y + \epsilon) - \log(G_{\sigma_s} * Y + \epsilon). \tag{10}$$

Với nhiều độ lệch chuẩn Gaussian, kết quả trung bình là:

$$r = \frac{1}{S}\sum_{s=1}^{S} r_s, \qquad \epsilon = 10^{-6}. \tag{11}$$

Các độ lệch chuẩn nhỏ nhấn mạnh biến đổi cục bộ, trong khi độ lệch chuẩn lớn thể hiện cấu trúc chiếu sáng rộng hơn. Kết hợp nhiều tỉ lệ giúp giảm phụ thuộc vào một mức làm mờ duy nhất.

3.5.2. Chuẩn hóa đầu ra trong dự án

Giá trị r trong miền log chưa nằm trong $[0, 1]$. Mã nguồn lấy percentile 1% và 99% trên toàn mảng kết quả, ký hiệu là q_1, q_{99}, rồi chuẩn hóa:

$$\widehat{X} = \text{clip}\left(\frac{r - q_1}{q_{99} - q_1}, 0, 1\right). \tag{12}$$

Nếu $q_{99} - q_1 < 10^{-6}$, hàm trả lại ảnh đầu vào để tránh chia cho khoảng quá nhỏ. Hai cấu hình tỉ lệ được thử là $[3, 10, 20]$ và $[5, 15, 30]$; notebook chọn cấu hình thứ hai.

Đây là MSR giản lược, không có bước phục hồi màu riêng của MSRCR và không có khối khử nhiễu chuyên biệt. Việc chuẩn hóa percentile làm kết quả phụ thuộc vào phân bố của chính ảnh đang xử lý. Một số pixel bị kéo đến 0 hoặc 1; quan hệ màu và độ sáng tuyệt đối có thể thay đổi đáng kể so với ảnh gốc.

3.5.3. Vì sao Retinex nhạy với nhiễu?

Vùng tối có giá trị Y nhỏ, trong khi đạo hàm của hàm log là $1/(Y + \epsilon)$. Các dao động nhỏ của nhiễu vì vậy có thể tạo chênh lệch lớn trong miền log. Phép trừ ảnh làm mờ còn nhấn mạnh thành phần biến thiên nhanh, bao gồm cả biên thật lẫn nhiễu. Sau bước kéo giãn percentile, những dao động này có thể tiếp tục được khuếch đại.

Khi ảnh chỉ bị Gamma làm tối, MSR có thể làm rõ cấu trúc tốt. Khi thêm nhiễu, cùng cấu hình có thể tạo màu giả và hạt rõ trên nền. Thí nghiệm ablation ở phần sau kiểm tra trực tiếp giả thuyết này bằng cách giữ nguyên $\gamma_d = 2, 2$ và thay đổi thành phần nhiễu.

3.6. Các phương pháp tăng cường dựa trên học sâu

3.6.1. Zero-DCE

Zero-DCE ước lượng các đường cong điều chỉnh cường độ phụ thuộc ảnh. Một dạng đường cong được mô tả trong nghiên cứu gốc là $I' = I + AI(1 - I)$, với tham số A được mạng dự đoán theo vị trí và được áp dụng lặp. Phương pháp học cách điều chỉnh ảnh bằng các ràng buộc không cần ảnh tham chiếu ghép cặp [3].

Trong dự án, Zero-DCE được dùng ở chế độ suy luận với checkpoint `Epoch99.pth`. Không tối ưu lại mạng trên GTSRB. Adapter chọn ảnh tăng cường từ đầu ra của mô hình, đưa về miền hợp lệ và cùng kích thước ban đầu. Vì đường cong tác động lên ảnh chứa nhiễu, đầu ra sáng hơn vẫn cần được kiểm tra về hạt và độ rõ nét số.

3.6.2. Retinexformer

Retinexformer kết hợp biểu diễn chiếu sáng với Transformer để phục hồi ảnh thiếu sáng. Khung một giai đoạn của phương pháp sử dụng thông tin chiếu sáng nhằm hỗ trợ xử lý các suy giảm và quan hệ giữa các vùng ảnh [4]. Báo cáo sử dụng nó như một đối chứng học sâu cho MSR, không đồng nhất hai phương pháp chỉ vì cùng dựa trên ý tưởng Retinex.

Checkpoint được dùng là bản LOL-v1 do tác giả công bố. Adapter nạp kiến trúc và trọng số, chạy suy luận, sau đó lấy phần đầu ra tương ứng ảnh gốc. Ảnh cần được đệm đến bội số

của 4 nếu kích thước chưa phù hợp; với crop 64×64, điều kiện này đã được thỏa mãn.

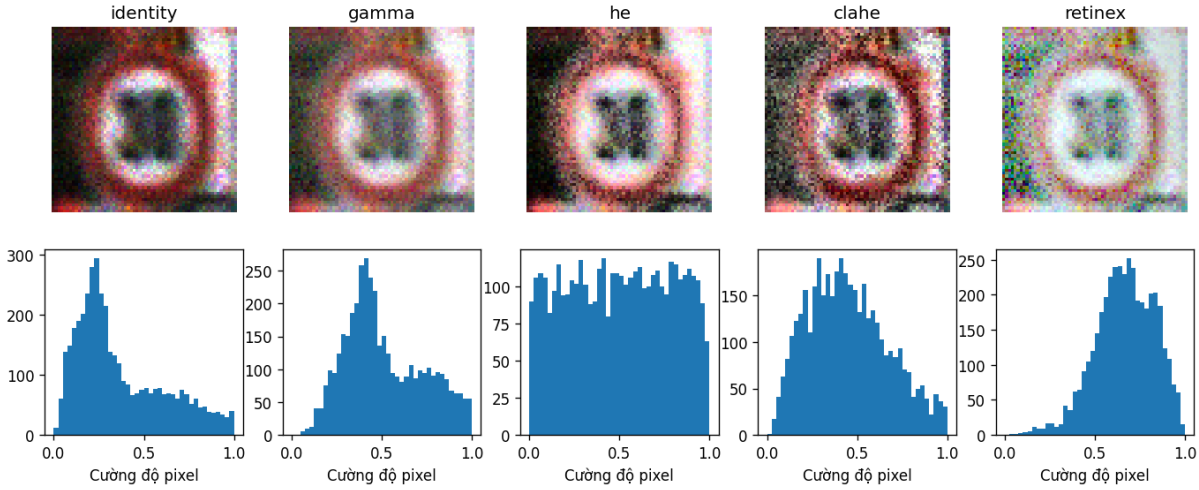
3.6.3. Tăng cường dựa trên diffusion trong miền wavelet

Phương pháp diffusion được chọn là Wavelet-based Diffusion LLIE. Nghiên cứu gốc kết hợp mô hình diffusion có điều kiện với biểu diễn wavelet và cơ chế phục hồi thành phần tần số cao [5]. Cách tiếp cận này hướng tới cân bằng thông tin chiếu sáng và chi tiết của ảnh.

Trong triển khai, mạng dùng trọng số trung bình trượt (EMA), 10 bước lấy mẫu và hạt giống suy luận được xác định theo mã ảnh. Nếu cần, ảnh được đệm lặp biên đến bội số của 32; đầu ra lấy từ trường `pred_x`, cắt về kích thước ban đầu và chặn $[0, 1]$. Nhiều bước suy luận làm chi phí lớn hơn đáng kể so với Gamma hoặc CLAHE.

Ba mô hình sâu đều được dùng nguyên trọng số tác giả. Vì dữ liệu học trước khác miền biển báo GTSRB và khác mô hình nhiễu tổng hợp đang khảo sát, không có cơ sở mặc định rằng chúng sẽ vượt mọi phương pháp truyền thống. Đây là một nội dung cần kiểm chứng bằng kết quả thực nghiệm thay vì suy đoán theo độ phức tạp của mô hình.

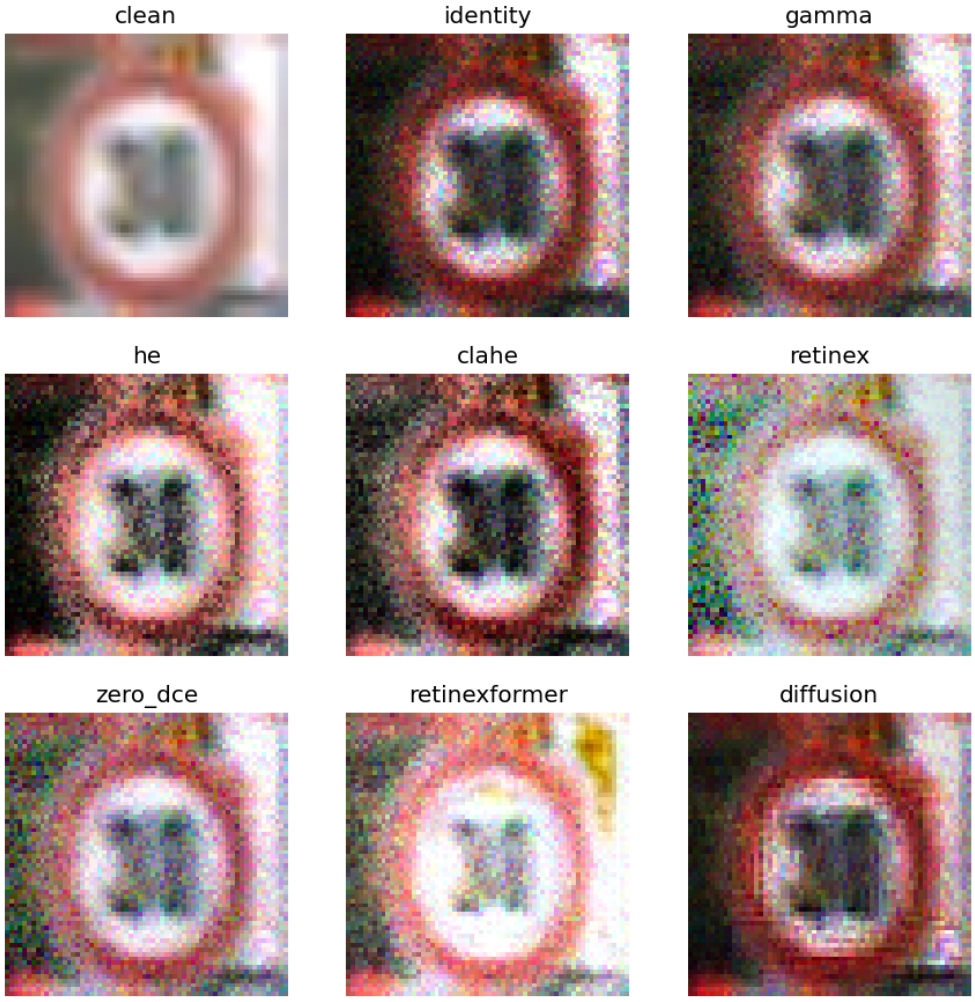
3.7. Minh họa trước và sau xử lý



Hình 4. Ảnh và histogram sau các phép xử lý truyền thống với tham số mặc định: Gamma 0,6; CLAHE clip limit 2, lưới 8×8; MSR $[3, 10, 20]$. Hình dùng để giải thích cơ chế, không phải kết quả của bộ tham số đã chọn.

Hình 4 cho thấy cùng một ảnh tối có thể được biến đổi thành nhiều phân bố sáng khác nhau. Gamma nâng phần lớn pixel tối; HE phân phối lại mức sáng trên toàn ảnh; CLAHE phụ thuộc từng vùng; MSR có thể tạo thay đổi mạnh về màu và độ tương phản. Việc histogram trải rộng sau xử lý chỉ chứng minh phép ánh xạ đã thay đổi phân bố, chưa chứng minh nội dung có ích đã được phục hồi.

Trong Hình 5, ảnh Zero-DCE và Retinexformer sáng lên rõ, nhưng nhiễu và sự biến đổi màu cũng cần được quan sát. MSR làm nền thay đổi mạnh, còn diffusion không nhất thiết tạo ảnh sáng nhất. Những nhận xét này chỉ có giá trị minh họa trên một mẫu; xếp hạng thuật toán phải dựa trên số liệu tổng hợp và hiệu quả nhận dạng ở các phần tiếp theo.



Hình 5. Cùng ảnh validation mức vừa qua bảy phương pháp với tham số đã chọn trên validation. Clean là ảnh tham chiếu, Identity là ảnh tối. Các kết quả được trích từ notebook ResNet-18.

3.8. Đánh giá chất lượng bằng PSNR và SSIM

3.8.1. Sai số bình phương trung bình và PSNR

Với X là ảnh gốc, $\widehat{X}$ là ảnh xử lý và $N = HWC$ là số phần tử RGB:

$$\mathrm{MSE} = \frac{1}{N}\sum_{i=1}^{N}(X_i - \widehat{X}_i)^2, \qquad \mathrm{PSNR} = 10\log_{10}\frac{1}{\mathrm{MSE}}. \tag{13}$$

Công thức dùng biên độ cực đại bằng 1 vì ảnh đã được chuẩn hóa. PSNR cao tương ứng sai số pixel nhỏ. MSE được tính với độ chính xác số thực 64 bit trong mã nguồn để giảm sai số cộng dồn. Nếu ảnh trùng hoàn toàn với tham chiếu, MSE bằng 0 và PSNR là vô hạn, không thay bằng một giá trị hữu hạn tùy ý.

PSNR được tính từng ảnh rồi lấy trung bình. Trung bình của log sai số khác log của sai số trung bình, nên không được gộp toàn bộ pixel của tập dữ liệu thành một MSE duy nhất rồi gọi đó là PSNR trung bình. Chỉ số cũng nhạy với thay đổi độ sáng toàn cục, dù ảnh sau thay

đổi vẫn có thể giữ được các nét phân lớp.

3.8.2. Độ tương đồng cấu trúc SSIM

SSIM xem xét thống kê cục bộ của hai ảnh, gồm độ sáng, độ tương phản và mức tương đồng cấu trúc [6]. Dạng thường dùng là:

$$\mathrm{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}. \tag{14}$$

Trong đó μ là trung bình cục bộ, σ^2 là phương sai, σ_{xy} là hiệp phương sai và các hằng số C_1, C_2 ổn định phép chia. Dự án dùng cửa sổ 7×7, miền giá trị 1, xử lý ba kênh màu, $K_1 = 0,01$, $K_2 = 0,03$, không dùng trọng số Gaussian và dùng hiệp phương sai mẫu.

SSIM bổ sung thông tin mà PSNR không thể hiện đầy đủ, song vẫn không thay thế metric nhận dạng. Nét chữ số bị sai ở một vùng nhỏ có thể không làm giảm mạnh điểm trung bình toàn ảnh. Khi ảnh đêm thực không có ảnh tham chiếu đồng vị trí, cũng không thể áp dụng trực tiếp PSNR/SSIM theo giao thức hiện tại.

4. THỬ NGHIỆM VÀ SO SÁNH KẾT QUẢ

4.1. Thiết lập mô hình kiểm chứng ResNet-18

ResNet-18 là kiến trúc mạng tích chập có kết nối phần dư, giúp học phép biến đổi thông qua tổng giữa nhánh đặc trưng và nhánh đi tắt [7]. Trong bài tập lớn, lớp phân loại cuối được thay bằng ánh xạ từ 512 đặc trưng sang 43 lớp biển báo. Mô hình khởi tạo từ trọng số ImageNet và được tinh chỉnh trên tập ảnh gốc GTSRB.

Đầu vào ở khối xử lý ảnh có dạng $B \times 3 \times 64 \times 64$ khi ghép batch. Trong hàm forward của ResNet-18, toàn bộ crop được nội suy song tuyến tính lên 224×224, có chống răng cưa, rồi chuẩn hóa theo trung bình $[0,485; 0,456; 0,406]$ và độ lệch chuẩn $[0,229; 0,224; 0,225]$. Chuẩn hóa được áp dụng đúng một lần. Đầu ra là ma trận $B \times 43$.

Trong huấn luyện, các phép tăng cường nhẹ gồm xoay tối đa $10°$, tịnh tiến tối đa 5%, thay đổi nhẹ sáng/tương phản/bão hòa và xóa ngẫu nhiên một vùng nhỏ. Không lật ngang biển báo vì có thể thay đổi ý nghĩa hướng di chuyển. Cụm từ "huấn luyện clean" ở đây nghĩa là không huấn luyện bằng mô hình thiếu sáng Gamma–Poisson–Gaussian của thí nghiệm, không có nghĩa là loại bỏ mọi augmentation.

Ba checkpoint tốt nhất trong notebook nằm ở epoch 12, 10 và 3 tương ứng seed 11, 22 và 33; huấn luyện dừng ở epoch 17, 14 và 8. Sau bước này, trọng số được giữ cố định cho mọi phương pháp xử lý. Do vậy, chênh lệch dự đoán trong mỗi checkpoint phản ánh ảnh hưởng của đầu vào đã được biến đổi.

Bảng 3. Cấu hình huấn luyện ResNet-18 dùng để kiểm chứng.

Thành phần	Thiết lập
Kiến trúc	ResNet-18, lớp cuối 43 đầu ra
Khởi tạo	ImageNet, tinh chỉnh toàn mạng
Dữ liệu huấn luyện	Ảnh gốc; không huấn luyện riêng theo enhancer
Bộ tối ưu	AdamW, learning rate 10^{-4}
Weight decay / batch size	10^{-4} / 32
Số epoch tối đa	20
Dừng sớm	Patience 5, min delta 0,001
Training seed	11, 22, 33
Chọn checkpoint	Macro-F1 validation clean tốt nhất

4.2. Chỉ số đánh giá nhận dạng

Accuracy là tỷ lệ mẫu được phân loại đúng:

$$\text{Accuracy} = \frac{N_{\text{đúng}}}{N_{\text{tổng}}}. \tag{15}$$

Với mỗi lớp c, Precision, Recall và F1 được tính từ số dự đoán đúng dương (TP), sai dương (FP) và sai âm (FN):

$$P_c = \frac{TP_c}{TP_c + FP_c}, \qquad R_c = \frac{TP_c}{TP_c + FN_c}, \tag{16}$$

$$F1_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}, \qquad \text{Macro-F1} = \frac{1}{43}\sum_{c=1}^{43} F1_c. \tag{17}$$

Mỗi lớp đóng góp như nhau vào Macro-F1, phù hợp với yêu cầu nhận dạng đầy đủ 43 loại biển báo. Weighted-F1 dùng số mẫu mỗi lớp làm trọng số và được lưu như metric bổ sung. Với tập con có đúng 10 ảnh/lớp, Weighted-F1 bằng Macro-F1 về mặt toán học; trên full-test có tần suất lớp khác nhau, hai chỉ số không nhất thiết bằng nhau.

Các bảng F1 trong báo cáo dùng Macro-F1 và ghi rõ đơn vị phần trăm. Chênh lệch giữa hai giá trị phần trăm được gọi là *điểm phần trăm*, tránh nhầm với tỷ lệ cải thiện tương đối.

4.3. Giao thức chọn tham số và tổng hợp số liệu

Mỗi phương pháp có tham số được chọn trên 1.290 ảnh validation. Điểm lựa chọn là Macro-F1 trung bình qua ba mức suy giảm, ba noise seed và ba training seed. Gamma thử ba số mũ; CLAHE thử sáu cấu hình; MSR thử hai bộ tỉ lệ. HE không có tham số cần chọn trong cài đặt này. Ba bộ tăng cường sâu giữ cấu hình và trọng số công bố.

Sau khi chọn cấu hình tốt nhất của từng phương pháp, quy tắc chọn pipeline xét các ứng viên có Macro-F1 cách điểm tốt nhất dưới 0,005, tương đương 0,5 điểm phần trăm, rồi ưu tiên

thời gian xử lý thấp hơn. Quy tắc này được xác định trước test. Trong notebook, diffusion có Macro-F1 validation khoảng 75,96%, cao hơn CLAHE 72,02%, do đó diffusion là phương pháp được chọn.

Số lượt đánh giá test của ma trận chính là:

$$3 + 3 \times 3 \times 3 \times 8 = 219. \tag{18}$$

Ba lượt đầu là clean cho ba checkpoint. Phần còn lại là tích của training seed, mức suy giảm, noise seed và tám phương pháp tính cả Identity. Với tập con 430 ảnh, có 94.170 dự đoán. Notebook lưu kết quả kiểm chứng gồm hash checkpoint, độ phủ mã ảnh/nhãn và việc tính lại metric nhận dạng.

Khi tổng hợp, trước hết lấy trung bình qua noise seed trong từng training seed, sau đó tính trung bình và độ lệch chuẩn mẫu qua ba training seed:

$$\overline{m}_t = \frac{1}{3}\sum_{n=1}^{3} m_{t,n}, \qquad \mu = \frac{1}{3}\sum_{t=1}^{3} \overline{m}_t, \qquad s = \sqrt{\frac{\sum_{t=1}^{3}(\overline{m}_t - \mu)^2}{2}}. \tag{19}$$

Ba mức noise seed không được xem là ba lần huấn luyện độc lập. Các chỉ số ảnh không phụ thuộc training seed khi bộ tăng cường và ảnh đầu vào giữ nguyên. Độ lệch chuẩn qua training seed vì thế không phải thước đo biến thiên chất lượng ảnh giữa các mẫu.

4.4. Nguồn kết quả và khả năng đối chiếu

Phân tích chi tiết sử dụng notebook đã chạy `GTSRB_LLIE_Complete_Pipeline_Executed.ipynb`. Tệp này chứa hình ảnh, 219 bản ghi kết quả ResNet-18 trên 430 ảnh, bảng ablation và đầu ra kiểm chứng [8]. Các bảng trong báo cáo được tổng hợp lại từ các bản ghi đó; hình minh họa được trích nguyên từ đầu ra notebook.

Bảng full-test 12.630 ảnh được lấy riêng từ README của dự án. Đây là thí nghiệm ResNet-18 khác với lần chạy notebook. Trong bản sao dự án dùng để soạn báo cáo chưa có thư mục kết quả full-test tương ứng, nên báo cáo không tuyên bố đã kiểm tra lại dự đoán từng ảnh của thí nghiệm này. Không ghép PSNR/SSIM của tập con với Macro-F1 full-test để tính tương quan.

4.5. Chất lượng ảnh trên tập con 430 ảnh

Ở mức nhẹ, Gamma đạt PSNR 23,94 dB và SSIM 0,7011, cao hơn Identity ở cả hai chỉ số. Điều này phù hợp với tính chất của phép biến đổi Gamma khi suy giảm chưa quá mạnh: một mức nâng sáng vừa phải giúp giảm sai lệch cường độ mà chưa phải trả giá lớn về nhiễu.

Ở mức vừa, Zero-DCE có PSNR cao nhất trong bảng (20,08 dB), còn CLAHE có SSIM cao nhất (0,5568). Diffusion đạt PSNR 14,90 dB, thấp hơn Identity 15,37 dB, nhưng SSIM tăng từ 0,3410 lên 0,5410. Hai thước đo đã đưa ra những đánh giá khác nhau: sai lệch cường độ không đồng nhất với mức bảo toàn cấu trúc.

Ở mức nặng, Retinexformer có PSNR cao nhất (17,39 dB), trong khi diffusion có SSIM cao nhất (0,4720). MSR có PSNR thấp ở cả ba mức và SSIM giảm rõ khi nhiễu mạnh. Các kết quả này cho thấy không có phương pháp đứng đầu đồng thời ở mọi chỉ số và mọi điều kiện.

Bảng 4. PSNR (dB) / SSIM của notebook ResNet-18 trên 430 ảnh. Mỗi ô ghi PSNR trước, SSIM sau.

Phương pháp	Tối nhẹ	Tối vừa	Tối nặng
Identity	19.49 / 0.6077	15.37 / 0.3410	13.79 / 0.2254
Gamma	23.94 / 0.7011	17.18 / 0.4498	14.84 / 0.2964
HE	11.45 / 0.3704	11.36 / 0.3237	11.06 / 0.2578
CLAHE	21.61 / 0.6369	19.29 / 0.5568	16.49 / 0.4107
MSR	8.70 / 0.3735	6.60 / 0.2409	7.26 / 0.1875
Zero-DCE	17.68 / 0.5067	20.08 / 0.4509	16.71 / 0.3157
Retinexformer	10.99 / 0.3853	14.78 / 0.4780	17.39 / 0.4349
Diffusion	14.50 / 0.5662	14.90 / 0.5410	14.88 / 0.4720

4.6. Accuracy và Macro-F1 trên cùng tập con

Bảng 5. Accuracy trung bình $\pm$ độ lệch chuẩn mẫu (%) của ResNet-18 trên 430 ảnh.

Phương pháp	Tối nhẹ	Tối vừa	Tối nặng
Identity	90.39 ± 2.30	73.05 ± 2.54	51.68 ± 2.51
Gamma	91.81 ± 1.57	74.83 ± 2.87	51.40 ± 3.34
HE	89.90 ± 3.32	72.48 ± 6.33	48.19 ± 8.84
CLAHE	91.94 ± 1.17	78.50 ± 1.13	55.17 ± 4.12
MSR	80.52 ± 3.79	48.06 ± 4.03	27.49 ± 3.94
Zero-DCE	87.55 ± 4.46	66.02 ± 5.40	42.35 ± 3.72
Retinexformer	79.69 ± 3.20	72.89 ± 3.82	49.59 ± 2.35
Diffusion	92.07 ± 2.20	82.95 ± 3.16	61.96 ± 5.09

Bảng 6. Macro-F1 trung bình $\pm$ độ lệch chuẩn mẫu (%) của ResNet-18 trên 430 ảnh.

Phương pháp	Tối nhẹ	Tối vừa	Tối nặng
Identity	90.38 ± 2.17	75.35 ± 2.55	54.81 ± 2.30
Gamma	91.85 ± 1.61	76.81 ± 2.83	55.21 ± 3.75
HE	90.22 ± 2.96	75.25 ± 5.53	52.46 ± 9.08
CLAHE	91.98 ± 1.30	80.14 ± 1.97	59.24 ± 5.37
MSR	81.55 ± 3.37	50.97 ± 4.09	30.37 ± 5.08
Zero-DCE	88.05 ± 3.96	69.30 ± 4.22	46.99 ± 3.19
Retinexformer	79.99 ± 4.01	73.63 ± 3.74	52.57 ± 2.41
Diffusion	92.01 ± 2.21	82.71 ± 3.08	63.72 ± 5.07

Trên ảnh clean, Accuracy đạt $98,53\% \pm 0,82$ và Macro-F1 đạt $98,50\% \pm 0,83$. Khi giữ nguyên ảnh thiếu sáng, Macro-F1 giảm còn 90,38%; 75,35% và 54,81% tương ứng mức nhẹ, vừa và nặng. Sự suy giảm này cho thấy mô hình đã học tốt trên ảnh gốc vẫn nhạy với thay đổi đầu vào.

Diffusion, được chọn bằng validation, đạt Macro-F1 92,01%; 82,71% và 63,72%. So với Identity, mức tăng lần lượt xấp xỉ 1,63; 7,36 và 8,91 điểm phần trăm. Ở mức vừa, Accuracy tăng từ 73,05% lên 82,95%, cho thấy lợi ích không chỉ xuất hiện ở một cách tổng hợp F1.

CLAHE là phương án truyền thống nổi bật: Macro-F1 đạt 91,98%; 80,14% và 59,24%. Riêng mức nhẹ, chênh lệch trung bình giữa CLAHE và diffusion chỉ khoảng 0,03 điểm phần trăm, nhỏ hơn nhiều độ lệch chuẩn giữa các seed. Không nên diễn giải khoảng cách rất nhỏ này thành bằng chứng ưu thế chắc chắn của một phương pháp.



Hình 6. Macro-F1 theo mức suy giảm trên tập con 430 ảnh của notebook ResNet-18. Các đường thể hiện xu hướng của cùng một bộ nhận dạng khi thay đổi phép xử lý đầu vào.

4.7. Đối chiếu trên toàn bộ 12.630 ảnh test

Bảng 7. Macro-F1 (%) của ResNet-18 trên full-test, theo bảng đã công bố trong README. Đây là lần chạy riêng với notebook 430 ảnh.

Phương pháp	Tối nhẹ	Tối vừa	Tối nặng
Identity	92.00 ± 1.71	78.04 ± 1.79	59.70 ± 1.64
Gamma	93.49 ± 1.25	79.77 ± 1.85	60.48 ± 2.59
HE	92.31 ± 1.96	77.27 ± 3.65	56.98 ± 6.48
CLAHE	94.35 ± 1.12	82.80 ± 1.46	64.31 ± 3.47
MSR	82.70 ± 3.12	55.71 ± 5.31	34.72 ± 5.71
Zero-DCE	89.65 ± 2.37	72.41 ± 3.12	51.27 ± 4.60
Retinexformer	82.85 ± 1.80	76.28 ± 2.31	56.67 ± 1.15
Diffusion	93.45 ± 1.80	83.87 ± 2.97	64.88 ± 3.84

Theo README, full-test clean có Accuracy $99,15\% \pm 0,30$ và Macro-F1 $98,90\% \pm 0,40$.

Pipeline diffusion đã chọn bằng validation đạt Macro-F1 93,45%; 83,87% và 64,88% ở ba mức. Mức tăng so với Identity tương ứng là 1,45; 5,83 và 5,18 điểm phần trăm.

CLAHE có Macro-F1 mức nhẹ cao nhất trong bảng full-test (94,35%). Tuy nhiên, đây là quan sát trên test, không phải căn cứ để thay phương pháp đã chọn trước đó. Ở mức vừa và nặng, diffusion có trung bình cao hơn CLAHE, nhưng kết luận về ý nghĩa thống kê cần phân tích chênh lệch ghép cặp từ dự đoán gốc.

Kết quả full-test củng cố nhận xét rằng thiếu sáng nặng vẫn là trường hợp khó và tăng sáng không phục hồi hoàn toàn hiệu năng clean. Các giá trị khác với bảng tập con là điều bình thường khi phạm vi mẫu và lần chạy thay đổi. Báo cáo sử dụng bảng này để đối chiếu xu hướng, không xem hai bảng là cùng một thí nghiệm.

5. THẢO LUẬN KẾT QUẢ VÀ PHÂN TÍCH TƯƠNG QUAN

5.1. Chất lượng ảnh cao có bảo đảm nhận dạng tốt?

Ở mức tối vừa của tập con, Zero-DCE đạt PSNR 20,08 dB, cao hơn diffusion 14,90 dB. Tuy nhiên, Macro-F1 của Zero-DCE chỉ đạt 69,30%, thấp hơn cả Identity 75,35%, trong khi diffusion đạt 82,71%. Nếu chỉ chọn theo PSNR, kết luận sẽ không phù hợp với mục tiêu nhận dạng của đề bài.

Một ví dụ khác xuất hiện ở mức nặng: Retinexformer có PSNR 17,39 dB nhưng Macro-F1 52,57%, còn diffusion có PSNR 14,88 dB và Macro-F1 63,72%. Sự khác biệt cho thấy tiêu chí giữ cường độ gần ảnh gốc không bảo đảm giữ đúng những đặc trưng mà ResNet-18 sử dụng.

SSIM có xu hướng phù hợp hơn trong một số điều kiện. Ở mức nặng, diffusion dẫn đầu cả SSIM lẫn Macro-F1 trong tập con. Dù vậy, ở mức vừa CLAHE có SSIM 0,5568, cao hơn diffusion 0,5410, nhưng Macro-F1 thấp hơn. SSIM vì thế cũng chỉ là chỉ số bổ trợ, không phải hàm thay thế trực tiếp cho hiệu năng nhận dạng.

Về mặt cơ chế, các phép xử lý có thể tạo sai lệch độ sáng hoặc màu trên vùng lớn nhưng vẫn làm rõ nét chữ và viền. Ngược lại, một thuật toán có thể giảm sai số trung bình bằng cách làm mượt, đồng thời xóa mất chi tiết nhỏ. Đây là những cách giải thích hợp lý cho chênh lệch metric; để xác định nguyên nhân của từng mẫu cần quan sát ảnh và dự đoán ghép cặp, không thể suy ra chắc chắn chỉ từ bảng trung bình.

5.2. Phương pháp phân tích tương quan

Tương quan được tính riêng theo từng mức suy giảm. Mỗi phương pháp là một điểm gồm chất lượng ảnh trung bình và hiệu năng nhận dạng trung bình trên cùng 430 ảnh. Có tám điểm khi tính cả Identity. Clean bị loại khỏi phân tích vì PSNR của ảnh so với chính nó là vô hạn và vì đây không phải một phương án phục hồi ảnh tối.

Hệ số Pearson đo mức liên hệ tuyến tính giữa hai đại lượng:

$$r = \frac{\sum_i (x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_i (x_i - \overline{x})^2}\sqrt{\sum_i (y_i - \overline{y})^2}}. \tag{20}$$

Spearman được tính bằng Pearson trên thứ hạng, dùng thứ hạng trung bình nếu có giá trị bằng nhau. Hệ số này giúp xem thứ tự phương pháp theo chất lượng ảnh có phù hợp với thứ tự theo khả năng nhận dạng hay không, kể cả khi quan hệ không tuyến tính.

Bảng 8. Tương quan chất lượng ảnh và nhận dạng của ResNet-18 trên tập con. Mỗi hàng có $n = 8$ phương pháp, cùng mức suy giảm.

Mức	Chất lượng	Nhận dạng	Pearson	Spearman
Nhẹ	PSNR	Accuracy	0.724	0.667
Nhẹ	PSNR	Macro-F1	0.715	0.667
Nhẹ	SSIM	Accuracy	0.753	0.667
Nhẹ	SSIM	Macro-F1	0.741	0.667
Vừa	PSNR	Accuracy	0.629	0.357
Vừa	PSNR	Macro-F1	0.660	0.333
Vừa	SSIM	Accuracy	0.777	0.714
Vừa	SSIM	Macro-F1	0.755	0.619
Nặng	PSNR	Accuracy	0.661	0.262
Nặng	PSNR	Macro-F1	0.686	0.286
Nặng	SSIM	Accuracy	0.709	0.571
Nặng	SSIM	Macro-F1	0.691	0.619

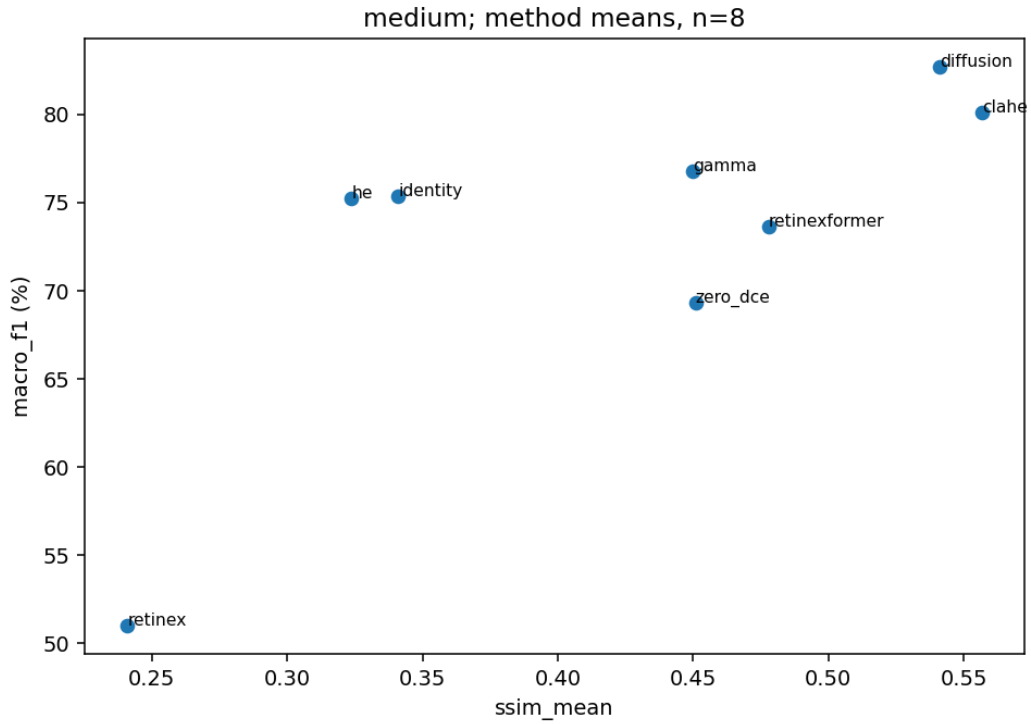
Các hệ số Pearson trong Bảng 8 đều dương, cho thấy chất lượng ảnh và hiệu năng nhận dạng có liên hệ cùng chiều khi xét toàn bộ tám phương pháp. Tuy nhiên, Spearman giữa PSNR và Macro-F1 giảm từ 0,667 ở mức nhẹ xuống 0,333 ở mức vừa và 0,286 ở mức nặng. Do đó, khi suy giảm mạnh hơn, xếp hạng theo PSNR trở nên ít phù hợp hơn với xếp hạng nhận dạng.

Với SSIM và Macro-F1, Spearman bằng 0,619 ở cả mức vừa và nặng, cao hơn tương ứng của PSNR. Quan sát này cho thấy thông tin cấu trúc hữu ích cho phân tích, nhưng không đủ để xác định một phương pháp tối ưu chỉ bằng SSIM. Các trường hợp đảo thứ hạng giữa CLAHE và diffusion vẫn tồn tại.

Số điểm trong phân tích rất nhỏ và các phương pháp sử dụng chung ảnh, nhiễu cũng như checkpoint. Vì vậy, các điểm không độc lập theo nghĩa thí nghiệm ngẫu nhiên. Một phương pháp có kết quả thấp ở cả hai trục, chẳng hạn MSR, có thể ảnh hưởng đáng kể đến Pearson. Báo cáo xem đây là phân tích khám phá, không suy ra quan hệ nhân quả và không dùng hệ số tương quan để bảo đảm hiệu quả trên ảnh đêm thực.

5.3. Ablation: tách tác động của độ tối và nhiễu

Để kiểm tra ảnh hưởng của từng thành phần suy giảm, notebook giữ $\gamma_d = 2,2$ và khảo sát bốn biến thể: chỉ Gamma; Gamma kèm Gaussian với $\sigma_n = 0,01$; Gamma kèm Poisson với $p = 60$; Gamma kèm cả hai. Các bộ tăng cường giữ nguyên tham số đã chọn; ResNet-18 giữ nguyên checkpoint. Không chọn lại phương pháp riêng cho từng hàng ablation.



Hình 7. Quan hệ giữa SSIM và Macro-F1 ở mức tối vừa, trích từ notebook ResNet-18. Mỗi điểm biểu diễn một phương pháp, không phải một ảnh độc lập.

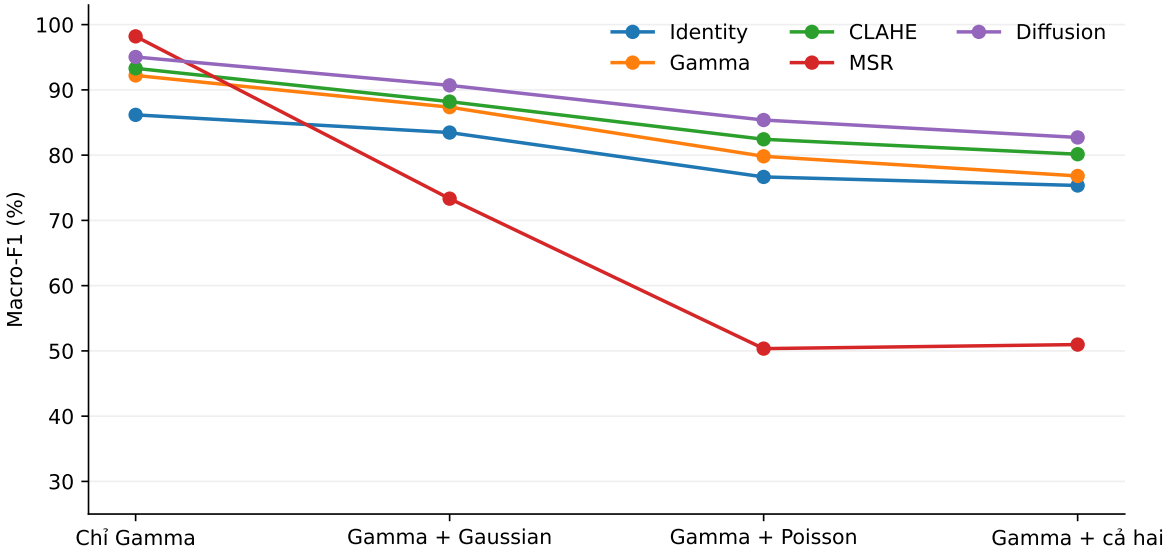
Ma trận phụ gồm $4 \times 3 \times 8 \times 3 = 288$ lượt trên 430 ảnh. Với trường hợp chỉ Gamma, thay noise seed không tạo ra nhiễu mới; các lượt tương ứng không được hiểu là những ảnh suy giảm độc lập. Bảng dưới trình bày trung bình Macro-F1 từ đầu ra notebook, làm tròn đến hai chữ số phần trăm.

Bảng 9. Macro-F1 (%) của ResNet-18 khi tách thành phần suy giảm ở mức Gamma 2,2.

Phương pháp	Chỉ Gamma	+ Gaussian	+ Poisson	+ Cả hai
Identity	86.17	83.46	76.66	75.35
Gamma	92.21	87.35	79.82	76.81
HE	93.49	85.07	77.29	75.25
CLAHE	93.30	88.20	82.43	80.14
MSR	98.20	73.33	50.35	50.97
Zero-DCE	97.48	87.13	71.57	69.30
Retinexformer	88.62	82.80	78.40	73.63
Diffusion	95.04	90.69	85.38	82.71

MSR đạt Macro-F1 98,20% khi chỉ có Gamma, nhưng giảm xuống 73,33% với Gaussian và 50,35% với Poisson. Khi thêm cả hai thành phần nhiễu, kết quả còn 50,97%, giảm 47,23 điểm phần trăm so với Gamma-only. Đây là bằng chứng rõ rằng phép xử lý hiệu quả với ảnh tối đơn thuần có thể không bền vững khi xuất hiện nhiễu.

Với Zero-DCE, Macro-F1 từ 97,48% ở Gamma-only giảm còn 69,30% khi có cả hai nhiễu. Diffusion giảm từ 95,04% xuống 82,71%, còn CLAHE giảm từ 93,30% xuống 80,14%. Trong cấu hình khảo sát, diffusion giữ hiệu năng tốt hơn khi nhiễu được đưa vào, dù không đứng đầu trường hợp chỉ Gamma.



Hình 8. Ảnh hưởng của từng thành phần nhiễu lên một số phương pháp đại diện. Biểu đồ dựng lại từ bảng ablation ResNet-18 trong notebook.

Trong nhiều hàng, Poisson gây giảm F1 mạnh hơn Gaussian. Kết luận này chỉ đúng với mức $p = 60$ và $\sigma_n = 0,01$ đã chọn; hai loại nhiễu không được cân bằng về năng lượng nên không thể kết luận Poisson luôn nghiêm trọng hơn Gaussian. Ngoài ra, MSR ở trường hợp cả hai nhiễu cao hơn một chút so với chỉ Poisson, cho thấy tác động kết hợp không nhất thiết đơn điệu trên metric phân loại.

5.4. Chi phí xử lý và khả năng triển khai

Bảng 10. Độ trễ trung bình của khối tăng cường ở mức vừa, trích từ 219 bản ghi notebook ResNet-18. Đơn vị ms/ảnh.

Phương pháp	Thời gian
Identity	0.118
Gamma	0.219
HE	0.190
CLAHE	0.400
MSR	2.111
Zero-DCE	1.797
Retinexformer	12.284
Diffusion	222.658

Notebook ghi thiết bị GPU Tesla T4; các phép truyền thống trong mã nguồn chạy trên CPU, còn các mô hình sâu chạy trên thiết bị suy luận được cấu hình. Độ trễ được đo cho khối enhancer, không bao gồm toàn bộ quy trình phát hiện, cắt biển báo và phân loại. Mốc Identity vẫn có chi phí gọi hàm và quản lý dữ liệu nên thời gian đo không bằng 0.

CLAHE mất khoảng 0,400 ms/ảnh, còn diffusion khoảng 222,658 ms/ảnh ở mức vừa của notebook. Tỷ lệ chênh lệch xấp xỉ 557 lần, trong khi Macro-F1 khác khoảng 2,57 điểm phần trăm. So sánh này cho thấy cần xét ngân sách tính toán khi lựa chọn phương pháp, nhưng không được suy ra tốc độ toàn hệ thống chỉ từ thời gian enhancer.

Nếu yêu cầu ưu tiên chất lượng nhận dạng trong giao thức đã khảo sát, diffusion là lựa chọn phù hợp với quyết định validation. Nếu cần một phương án xử lý nhẹ, dễ triển khai, CLAHE là ứng viên thực tế để đánh giá tiếp. Việc thay đổi mục tiêu sang ràng buộc thời gian phải được quyết định và kiểm tra trên validation, không chọn lại sau khi xem test.

5.5. Giới hạn của thực nghiệm

Thứ nhất, ảnh thiếu sáng là ảnh tổng hợp trong miền RGB. Mô hình chưa mô tả đầy đủ phản ứng cảm biến, cân bằng trắng, nén ảnh, mưa, phản xạ gương, lóa đèn hoặc nhòe chuyển động. Khả năng khái quát đến camera giao thông ban đêm vì thế cần dữ liệu thực riêng.

Thứ hai, dữ liệu đầu vào đã được cắt biển báo. Kết quả chưa phản ánh lỗi phát hiện ROI trong ảnh toàn cảnh. Nếu detector bỏ sót hoặc cắt sai vị trí, bộ tăng cường crop không thể tự sửa được vấn đề đó.

Thứ ba, khảo sát chi tiết dùng 430 ảnh cân bằng lớp và ba training seed. Đây là quy mô phù hợp để khảo sát nhiều biến thể nhưng chưa đủ khẳng định ưu thế thống kê cho những khoảng cách rất nhỏ. Kết quả full-test được đối chiếu từ tài liệu dự án và cần bộ dự đoán gốc để kiểm định lại chênh lệch ghép cặp.

Thứ tư, lưới tham số còn hữu hạn và các bộ tăng cường sâu dùng trọng số đã học trên miền khác. Từ "tối ưu" trong báo cáo được hiểu là tốt nhất theo tiêu chí validation trong tập phương án đã khảo sát, không phải tối ưu tuyệt đối cho mọi dữ liệu và mọi thiết bị.

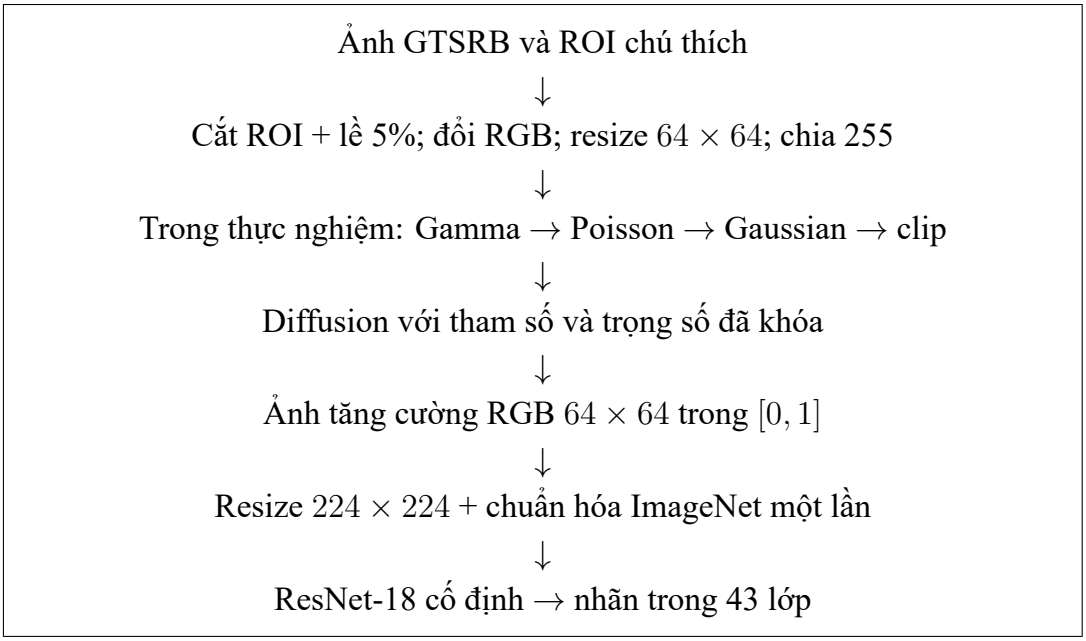
6. ĐỀ XUẤT QUY TRÌNH TIỀN XỬ LÝ

6.1. Tiêu chí lựa chọn

Mục tiêu cuối của đề bài là cải thiện nhận dạng biển báo, vì vậy Macro-F1 validation được dùng làm tiêu chí chọn chính. Accuracy kiểm tra mức đúng chung; PSNR và SSIM giải thích ảnh đã thay đổi thế nào; thời gian xử lý thể hiện chi phí triển khai. Cách tổ chức này giữ vai trò của chất lượng ảnh trong phân tích nhưng tránh lựa chọn một phương pháp chỉ vì nó tạo ảnh có PSNR cao.

Quyết định cần được thực hiện trước khi xem kết quả test. Với từng enhancer, chọn tham số trên validation; sau đó so các cấu hình đã chọn bằng cùng tập ảnh và cùng checkpoint. Nếu các phương án nằm trong khoảng dung sai 0,5 điểm phần trăm Macro-F1, ưu tiên phương án nhanh hơn theo quy tắc đã cài đặt. Trong thí nghiệm hiện tại, diffusion vượt ngưỡng gần tương đương so với CLAHE nên được chọn làm pipeline chính.

6.2. Quy trình được lựa chọn



Hình 9. Quy trình tiền xử lý và nhận dạng được chọn. PSNR/SSIM đo trước bước resize cho ResNet-18, với ảnh gốc tương ứng.

Trong quy trình này, bước tạo suy giảm chỉ phục vụ thực nghiệm. Khi tiếp nhận một crop thiếu sáng thực, ảnh đó đi trực tiếp vào bộ tăng cường sau chuẩn hóa, không bị làm tối thêm. Ảnh tham chiếu chỉ được sử dụng ở nhánh đánh giá chất lượng khi tồn tại cặp dữ liệu phù hợp.

Diffusion dùng trọng số EMA và 10 bước lấy mẫu như cấu hình đã khảo sát. Kết quả được kiểm tra kích thước, số kênh và giá trị hữu hạn trước khi chặn về $[0, 1]$. ResNet-18 giữ nguyên checkpoint, không thích nghi lại theo ảnh tăng cường trong quá trình test. Mỗi phương pháp còn lại được thay vào đúng vị trí enhancer khi thực hiện phép so sánh.

6.3. Phương án xử lý nhẹ bằng CLAHE

Đối với tình huống ngân sách xử lý hạn chế, CLAHE với clip limit 2 và lưới 4×4 là ứng viên đáng ưu tiên trong các phương pháp truyền thống. Trên tập con, cấu hình này cải thiện Macro-F1 ở cả ba mức so với Identity và có chi phí thấp. Khối xử lý được mô tả theo thứ tự:

$$Y_{\text{RGB}} \longrightarrow YCrCb \longrightarrow \text{CLAHE}(Y) \longrightarrow RGB. \tag{21}$$

Hai kênh sắc độ được giữ trong quá trình cân bằng, chỉ kênh độ sáng được biến đổi. Đầu ra đưa về số thực $[0, 1]$ trước khi đi qua cùng ResNet-18. Cấu hình này không cần tham số theo từng lớp biển báo và không cần ảnh tham chiếu khi suy luận.

Tuy nhiên, báo cáo không đề xuất tự động chuyển giữa CLAHE và diffusion theo mức tối ngay từ kết quả hiện có. Một cơ chế chọn thích nghi sẽ cần tiêu chí đo mức tối, ngưỡng quyết định và đánh giá validation riêng. Các mức mild/medium/severe trong thí nghiệm là tham số sinh dữ liệu đã biết, không phải nhãn điều kiện luôn có sẵn ở thời điểm triển khai.

6.4. Tổ chức cài đặt và tái lập

Bảng 11. Các thành phần mã nguồn liên quan trực tiếp đến quy trình.

Thành phần	Trách nhiệm
`src/data.py`	Cắt ROI, chia track, kiểm kê và chọn tập con
`src/degradation.py`	Sinh ảnh tối bằng Gamma, Poisson và Gaussian
`src/enhancement.py`	Bốn phép truyền thống và adapter cho ba mô hình sâu
`src/model.py`	ResNet-18, resize và chuẩn hóa đầu vào
`src/metrics.py`	PSNR, SSIM, Accuracy và F1-score
`src/experiment.py`	Chọn tham số, khóa giao thức, đánh giá
`src/reporting.py`	Tổng hợp metric, tương quan và biểu đồ
`configs/resnet18.json`	Cấu hình thống nhất của thí nghiệm

Quá trình tái lập cần sử dụng cùng cấu hình, danh sách mã ảnh, trọng số và phiên bản mã nguồn. Sau khi chuẩn bị dữ liệu, huấn luyện ba seed clean, chọn enhancer trên validation và khóa giao thức. Chỉ sau đó mới chạy test. Thí nghiệm ablation sử dụng lại checkpoint và tham số đã chọn, thay đổi riêng mô hình suy giảm.

Notebook đã chạy là tài liệu thực nghiệm kèm kết quả của báo cáo. Trong thư mục báo cáo, các bảng được lưu ở dạng CSV, kèm mã trích xuất và thông tin SHA-256 của nguồn. Việc lưu cả số liệu và nguồn giúp kiểm tra một ô trong bảng mà không phải đọc lại toàn bộ log hoặc huấn luyện mô hình.

6.5. Hướng cải thiện quy trình

Kết quả ablation cho thấy nhiễu là một yếu tố cần ưu tiên. Một hướng mở rộng hợp lý là khảo sát khử nhiễu trước hoặc phối hợp với tăng sáng, nhưng phải kiểm tra xem bộ lọc có làm mất nét chữ số hay không. Đây là hướng nghiên cứu tiếp theo, chưa được xem là thành phần đã triển khai hoặc đã chứng minh tốt hơn trong báo cáo.

Một hướng khác là đánh giá trên dữ liệu thiếu sáng thực có nhãn tương thích, và bổ sung chỉ số riêng cho biên, màu hoặc khả năng đọc nét số. Nếu có ảnh tham chiếu ghép cặp chính xác, có thể tiếp tục dùng PSNR/SSIM; nếu không, cần thiết kế giao thức khác. Mọi thay đổi đều phải được lựa chọn trên validation và kiểm tra bằng cùng một bộ nhận dạng để giữ đúng mục tiêu khảo sát xử lý ảnh.

7. KẾT LUẬN

Bài tập lớn đã xây dựng quy trình khảo sát ảnh hưởng của xử lý ảnh đến nhận dạng biển báo giao thông thiếu sáng trên GTSRB. Quy trình mô phỏng suy giảm bằng Gamma kết hợp Poisson và Gaussian ở ba mức; so sánh bảy phương pháp tăng cường với mốc Identity; đánh giá PSNR, SSIM và hiệu năng của cùng kiến trúc ResNet-18. Trọng tâm của nghiên cứu là tác động của các phép biến đổi ảnh đến thông tin phục vụ nhận dạng.

Kết quả cho thấy không có phương pháp tăng cường nào đồng thời đứng đầu mọi metric.

Gamma có chất lượng pixel tốt ở mức nhẹ; CLAHE là phương án truyền thống có hiệu quả và chi phí thấp; diffusion được chọn trên validation và cải thiện Macro-F1 ở cả ba mức suy giảm. Trên tập con 430 ảnh, Macro-F1 của diffusion đạt 92,01%; 82,71% và 63,72%, cao hơn Identity lần lượt khoảng 1,63; 7,36 và 8,91 điểm phần trăm.

Phân tích tương quan khẳng định rằng PSNR và SSIM có liên hệ với khả năng nhận dạng nhưng không thay thế được Accuracy và F1-score. Đặc biệt, thứ hạng PSNR phù hợp kém hơn với thứ hạng Macro-F1 khi mức suy giảm tăng. Việc lựa chọn tiền xử lý cần dựa trên mục tiêu tác vụ, đồng thời dùng chất lượng ảnh và quan sát trực quan để giải thích kết quả.

Thí nghiệm ablation làm rõ vai trò của nhiễu: MSR đạt Macro-F1 98,20% khi chỉ làm tối bằng Gamma nhưng còn 50,97% khi thêm cả Poisson và Gaussian. Vì vậy, đánh giá chỉ trên ảnh bị giảm sáng đơn thuần có thể dẫn đến lựa chọn không phù hợp với điều kiện có nhiễu. Khả năng hạn chế khuếch đại nhiễu và bảo toàn chi tiết là yếu tố quan trọng bên cạnh mức nâng sáng.

Trong tập phương án đã khảo sát, báo cáo đề xuất pipeline diffusion với tham số đã khóa cho mục tiêu ưu tiên Macro-F1, và xem CLAHE là ứng viên xử lý nhẹ khi có ràng buộc thời gian. Kết luận có phạm vi ở ảnh crop GTSRB với suy giảm tổng hợp; mở rộng sang camera ban đêm thực, phát hiện biển báo trong toàn cảnh và các cơ chế khử nhiễu phối hợp cần thực nghiệm bổ sung.

———- HẾT ———-

TÀI LIỆU THAM KHẢO

[1] J. Stallkamp, M. Schlipsing, J. Salmen và C. Igel, "The German Traffic Sign Recognition Benchmark: A multi-class classification competition," *International Joint Conference on Neural Networks*, 2011. Thông tin và nguồn dữ liệu được ghi trong `DATASETS.md` của dự án.

[2] OpenCV, "Histograms – 2: Histogram Equalization," tài liệu kỹ thuật về HE và CLAHE. [Trực tuyến]. https://docs.opencv.org/4.x/d5/daf/tutorial_py_histogram_equalization.html. Truy cập ngày 17/10/2026.

[3] C. Guo và cộng sự, "Zero-Reference Deep Curve Estimation for Low-Light Image Enhancement," *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020. [Trực tuyến]. https://arxiv.org/abs/2001.06826.

[4] Y. Cai, H. Bian, J. Lin, H. Wang, R. Timofte và Y. Zhang, "Retinexformer: One-stage Retinex-based Transformer for Low-light Image Enhancement," *IEEE/CVF International Conference on Computer Vision*, tr. 12504–12513, 2023. [Trực tuyến]. https://arxiv.org/abs/2303.06705.

[5] H. Jiang, A. Luo, S. Han, H. Fan và S. Liu, "Low-Light Image Enhancement with Wavelet-based Diffusion Models," *ACM Transactions on Graphics*, 2023. [Trực tuyến]. https://arxiv.org/abs/2306.00306.

[6] Z. Wang, A. C. Bovik, H. R. Sheikh và E. P. Simoncelli, "Image Quality Assessment: From Error Visibility to Structural Similarity," *IEEE Transactions on Image Processing*, tập 13, số 4, tr. 600–612, 2004. [Trực tuyến]. https://www.cns.nyu.edu/~lcv/ssim/.

[7] K. He, X. Zhang, S. Ren và J. Sun, "Deep Residual Learning for Image Recognition," *IEEE Conference on Computer Vision and Pattern Recognition*, 2016. [Trực tuyến]. https://arxiv.org/abs/1512.03385.

[8] Nhóm thực hiện, *Low-light Enhancement for Traffic Sign Recognition*. Mã nguồn, cấu hình ResNet-18, README và notebook đã thực thi; bản sao dự án dùng soạn báo cáo ngày 17/10/2026. [Trực tuyến]. https://github.com/ZesyC/low-light-enhancement-for-traffic-sign-recognition.

Nguồn thực nghiệm chi tiết: notebook `GTSRB_LLIE_Complete_Pipeline_Executed.ipynb`, các cell 7–9 (minh họa xử lý ảnh), 13–14 (validation và tham số đã chọn), 16–17 (kết quả test), 20 (ablation), đánh số cell từ 0. Bảng full-test lấy từ README và được ghi nguồn riêng trong nội dung. Bảng tổng hợp, tương quan và thông tin kiểm tra nguồn được lưu kèm báo cáo trong thư mục `evidence/`.